Proyecto de Minería de Datos

Avance 1 — Análisis y procesamiento del dataset Instacart

Dataset	Instacart Online Grocery Basket Analysis
Unidad base	Producto perteneciente a un pedido realizado por un usuario
Líneas de aprendizaje	Asociación · Clustering · Clasificación
Dataset base procesado	32,434,489 registros × 15 variables
Muestra entregable	100 registros × 9 variables

Reporte elaborado a partir del notebook de trabajo proporcionado para el Avance 1.

1. Definición del problema y contexto

El proyecto estudia el comportamiento de compra a partir de datos históricos de transacciones de Instacart. El conjunto contiene información de usuarios, pedidos, productos y categorías, además de variables temporales y la variable `reordered`, que indica si un producto había sido adquirido previamente.

El problema general planteado consiste en determinar cómo las técnicas de minería de datos pueden utilizarse para identificar patrones de compra, caracterizar perfiles de usuarios y analizar el comportamiento de recompra.

Objetivo general

Analizar el comportamiento de compra de los usuarios mediante técnicas de minería de datos aplicadas al conjunto de datos de Instacart, con el propósito de identificar relaciones entre productos, segmentar usuarios de acuerdo con sus características de compra y analizar los factores relacionados con la recompra de productos, mediante el procesamiento y preparación de los datos para las etapas posteriores de análisis y aprendizaje automático.

Preguntas de análisis

• ¿Qué productos tienden a ser adquiridos conjuntamente dentro de los pedidos?

• ¿Es posible identificar grupos de usuarios con comportamientos de compra similares?

• ¿Qué características del comportamiento de compra se encuentran relacionadas con la recompra de un producto?

2. Fuente de datos

El notebook identifica como fuente el dataset **Instacart Online Grocery Basket Analysis**, disponible en Kaggle. El conjunto está compuesto por seis archivos CSV que permiten relacionar usuarios, pedidos, productos, pasillos y departamentos.

Archivo	Contenido
aisles.csv	Pasillos o categorías de productos
departments.csv	Departamentos de productos
products.csv	Información de los productos
orders.csv	Información de las órdenes y usuarios
order_products__prior.csv	Productos asociados con órdenes anteriores
order_products__train.csv	Productos asociados con las órdenes de entrenamiento

Nota: el notebook documenta la fuente como Kaggle, pero no incluye en la sección revisada una referencia bibliográfica o URL formal. Conviene añadir esa referencia en la versión final del documento si el formato de la materia la exige.

3. Análisis estadístico y principales hallazgos

El análisis estadístico se concentró en variables relacionadas con el comportamiento de las órdenes, evitando interpretar identificadores como variables cuantitativas.

Aspecto	Resultado documentado
Número de orden	Media ≈ 17.15; mediana = 11; rango 1–100
Día de la semana	El día codificado como 0 concentra 17.56%; el día 4 presenta 12.46%

Aspecto	Resultado documentado
Hora de compra	10:00 es la hora con mayor proporción (8.43%); 9:00–16:00 concentra 64.93%
Intervalo entre órdenes	Media ≈ 11.11 días; mediana = 7; 50.4% de los intervalos está entre 0 y 7 días
Recompra	58.97% de los registros de productos tienen reordered=1 y 41.03% reordered=0
Productos por orden	Media ≈ 10.09; mediana = 8; 50% central entre 5 y 14; máximo 145
Órdenes por usuario	206,209 usuarios; media ≈ 16.59 órdenes; mediana = 10; máximo 100

En conjunto, el análisis muestra una actividad de compra no uniforme por día y hora, una concentración importante de intervalos cortos entre órdenes, un peso considerable de las recompras y una variabilidad apreciable en la cantidad de órdenes por usuario.

4. Procesamiento de los datos

Se estableció como unidad de análisis del dataset base el producto perteneciente a un pedido realizado por un usuario. La estructura se construyó mediante integraciones sucesivas y validaciones de claves.

Etapa	Resultado
order_products_prior + orders	32,434,489 registros conservados; unión mediante order_id
Integración con products	Se incorporan product_name, aisle_id y department_id
Integración con aisles y departments	Se incorporan los nombres descriptivos de categorías
Dataset integrado	32,434,489 × 15
Faltantes	Se trataron los faltantes de days_since_prior_order; se conservaron los registros
Consistencia	0 duplicados completos; reordered ∈ {0,1}; sin identificadores faltantes

Tratamiento de valores faltantes

El notebook identifica los valores faltantes de `days_since_prior_order` como correspondientes a los primeros pedidos. Se decidió conservar esos registros y sustituir el valor faltante por 0 para disponer de una variable numérica sin valores faltantes. La variable `order_number` se conserva como contexto adicional.

5. Datasets preparados para aprendizaje

Dataset	Unidad de análisis	Resultado
Asociación	Pedido / transacción	3,214,874 transacciones; cada pedido contiene una lista de product_id
Clustering	Usuario	206,209 usuarios × 6 variables; sin duplicados ni faltantes
Clasificación	Registro de producto dentro de pedido	32,434,489 × 9; reordered como variable objetivo

Dataset de asociación

Se agruparon los productos por `order_id`, utilizando `product_id` para representar cada transacción. Se verificó que las 3,214,874 filas correspondan a 3,214,874 pedidos únicos. El número de productos por transacción presenta media ≈ 10.09, mediana = 8 y máximo = 145.

Dataset de clustering

Se construyó una fila por usuario con las variables: número de pedidos, productos comprados, productos recomprados, promedio de productos por pedido y días promedio entre pedidos, además de user_id. El resultado contiene 206,209 usuarios y no presenta duplicados ni valores faltantes.

Dataset de clasificación

Se seleccionaron nueve variables relacionadas con el contexto de compra. La variable objetivo es `reordered`. El dataset contiene 32,434,489 registros y no presenta valores faltantes. La distribución documentada es: 19,126,536 registros con reordered=1 y 13,307,953 con reordered=0.

6. Muestra y archivo CSV

Se seleccionó una muestra aleatoria de 100 registros del dataset de clasificación mediante `sample(n=100, random_state=42)`. La verificación final del notebook confirma 100 registros, 9 variables y 0 valores faltantes.

Característica	Resultado
Registros	100
Variables	9
Valores faltantes	0
Semilla aleatoria	42
Archivo	dataset_procesado_100_registros.csv

7. Revisión del notebook antes de la entrega

La revisión del notebook no encontró celdas guardadas con errores de ejecución. Los resultados finales de procesamiento y exportación son coherentes con los requisitos del Avance 1. Sin embargo, se identificaron algunos detalles de organización que conviene corregir antes de entregar la versión final del notebook.

Orden de las secciones 7.6–7.8: La conclusión 7.6.4 aparece después de una sección titulada 'Exportacion'. Conviene colocar 7.6.4 inmediatamente después de 7.6.3 y antes de 7.7.

Celda 'Exportacion': Existe un encabezado aislado '# Exportacion' antes de la conclusión 7.6.4. Puede eliminarse para evitar una sección duplicada.

Duplicación de exportación: La muestra se genera y se exporta primero dentro de la celda de selección y posteriormente se vuelve a exportar en 7.8. Para una presentación limpia, se recomienda que 7.7 solo seleccione la muestra y 7.8 sea la única sección que exporte el CSV.

Texto de 7.6.1: La explicación menciona inicialmente product_name, pero el código utiliza product_id para la representación de las transacciones. Conviene alinear el texto con la implementación actual.

Referencia de la fuente: La fuente está identificada como Kaggle, pero conviene agregar la referencia bibliográfica o URL correspondiente en el documento final si es requerida por la materia.

8. Conclusión del Avance 1

El notebook documenta las etapas solicitadas para el Avance 1: definición del problema y contexto, fuente de datos, análisis estadístico, integración y procesamiento de los datos, construcción de estructuras destinadas a aprendizaje y generación de una muestra aleatoria de 100 registros.

El dataset base procesado conserva 32,434,489 registros y 15 variables después de las integraciones, tratamiento de valores faltantes y verificaciones de consistencia. A partir de esta estructura se generaron representaciones específicas para asociación, clustering y clasificación. Finalmente, se obtuvo una muestra reproducible de 100 registros y 9 variables, sin valores faltantes, lista para ser entregada como CSV.

Las técnicas de asociación, clustering y clasificación quedan planteadas como etapas posteriores del proyecto; en este avance se documenta la preparación de los datos necesaria para aplicarlas.